

• 什么是人工智能？

What is AI?

Thinking Humanly “The exciting new effort to make computers think ... <i>machines with minds</i> , in the full and literal sense.” (Haugeland, 1985) “[The automation of] activities that we associate with human thinking, activities such as decision-making, problem solving, learning ...” (Bellman, 1978)	Thinking Rationally “The study of mental faculties through the use of computational models.” (Charniak and McDermott, 1985) “The study of the computations that make it possible to perceive, reason, and act.” (Winston, 1992)
Acting Humanly “The art of creating machines that perform functions that require intelligence when performed by people.” (Kurzweil, 1990) “The study of how to make computers do things at which, at the moment, people are better.” (Rich and Knight, 1991)	Acting Rationally “Computational Intelligence is the study of the design of intelligent agents.” (Poole <i>et al.</i> , 1998) “AI ... is concerned with intelligent behavior in artifacts.” (Nilsson, 1998)

Four schools of thoughts

- 以人类思维为目标（Thinking Humanly）
 - 需要确定人类如何思考（1960年代的“认知革命”）
 - 需要对大脑内部活动建立科学理论
 - 抽象层次是什么？侧重“知识”还是“电路”？
 - 如何进行验证？
 - 现今认知科学与人工智能是不同的学科
- 以理性思维为目标（Thinking Rationally）
 - 若干希腊学派发展了各种形式的逻辑：用于表示与推导思想的符号和推理规则
 - 问题：
 - 并非所有知识都能用逻辑符号表示
 - 计算复杂度爆炸（computational blow up）
- 以人类行为为目标（Acting Humanly）
 - 以人类行为为目标：图灵测试
 - 图灵测试（Alan Turing, 1950）：若计算机能骗过人类审问者，则通过智能测试
 - 人工智能的主要组成：知识、推理、语言理解、学习
 - 以理性思维为目标：“思维法则”
- 以理性行为为目标（Acting Rationally）
 - 代理做“正确的事”：在已有信息（环境、背景知识等）下，期望最大化目标的实现
 - 理性代理：采取行动以实现最佳结果；在存在不确定性（随机环境）时，追求期望的最佳结果

- 亚里士多德（《尼各马可伦理学》）：“每一门艺术与每一项探究，以及每一行动与追求，都被认为以某种善为目的。”

- 人工智能的历史


- 萌芽期（1940-1950）
- 早期热情与高度期望（1950-1970）
- 基于知识的人工智能（1970-1990）
- 人工智能走向“科学化”（1990-至今）
- 注：人工智能是一个历史悠久的广泛领域，经历过起伏、成败、乐观与失望、大量资助随后削减等循环。

- 代理 Agent：


- 分类（按照 通用性递增顺序 排列）

- 简单反射型智能体（Simple reflex agents）

- 简单反射型智能体根据当前状态选择行动，只关注当前感知状态，忽略感知历史。
 - 简单但有限：仅在环境是完全可观察的情况下有效，即正确的行动仅基于当前感知状态。
 -



- 以吸尘器为例：
 - 感知：位置和内容（位置传感器、污垢传感器）
 - 动作：左，右，吸，无动作
 -




```

Function Vacuum_agent (location, content)
return action
  if content = Dirty then return Suck
  else if location = A then return Right
  else return Left

```


• 基于模型的反射型智能体（Model-based reflex agents）

- 通过记录当前无法观察到的环境部分，处理部分可观察性。
- 内部状态基于感知历史（最佳猜测）。
- 世界模型基于以下两个方面：
 - (1) 世界如何独立于智能体演化；
 - (2) 智能体的动作如何影响世界。




• 基于目标的智能体（Goal-based agents）

- 仅了解环境的当前状态还不够；智能体还需要一些目标信息。
- 智能体程序将目标信息与环境模型结合，选择能够实现该目标的行动。
- 以“如果我做A，会发生什么？”的方式来考虑未来。
- 具备灵活性，因为支撑决策的知识被显式表示，并且可以被修改。




• 基于效用的智能体（Utility-based agents）

- 有时仅仅达到期望的目标还不够；我们可能希望以更快、更安全或更便宜的方式到达目的地。
- 应当考虑智能体的“幸福度”，我们称之为“效用”（utility）。
- 效用函数是衡量智能体性能的指标。
- 由于世界存在不确定性，效用型智能体会选择能使期望效用最大化的行动。
-




- 所有这些类型都可以概括为**学习型智能体（Learning agents）**，它们能够改善自身性能并生成更优的动作。智能体可以通过学习来提升表现。这是对智能体程序的一种高层次呈现/描述。
 - 手工为智能体编程可能非常繁琐。“某种更为快捷的方法是可取的。”——艾伦·图灵，1950。
 - 四个概念性组成部分：
 - 学习模块（Learning element）：负责改进。
 - 性能模块（Performance element）：负责选择对外部环境的行动；到目前为止我们把它视为“智能体”本身。


- 评价器/批评家（Critic）：依据既定的性能标准评估智能体做得如何。
- 问题生成器（Problem generator）：让智能体能够进行探索。
-



- 通过传感器感知周围环境
- 通过执行器对环境采取行动
- 代理程序以以下循环运行：（1）感知 perceive （2）思考 think （3）行动 act



- 智能代理 Intelligent Agent：
 - 人工智能中的核心概念之一是“智能体”（intelligent agent）。
 - 人工智能的目标是设计有用、能对环境做出反应、具备自主性，甚至能够进行社会互动并具备前瞻性的智能体。
 - 智能体通过“感知”（percept /观测）来获取环境信息，并通过“执行器”（actuators）对环境施加动作。
 - “性能度量”（performance measure）用来评估智能体的行为好坏。
 - 行为旨在最大化“期望性能度量”的智能体称为“理性智能体”（rational agent）。
 - 智能体（Agent）= 架构（Architecture）+ 程序（Program） 【二者互补兼容】
 -



• 代理状态（表达能力依次增强）：

- 原子表示（Atomic Representation）：世界的每一种状态都是一个没有内部结构的黑匣子。

- 例如，寻找一条行车路线，每个州都是一个城市。
- AI 算法：搜索、游戏、马尔可夫决策过程、隐藏马尔可夫模型等。


•



- 因式分解表示（Factored Representation）：每个状态都有一些属性值属性。

- 例如，GPS 位置、油箱中的气体量。
- AI 算法：约束满足和贝叶斯网络。


•



- 结构化表示（Structured Representation）：状态对象之间的关系可以显式表达。

- AI 算法：一阶逻辑、知识型学习、自然语言理解。

•



•


代理和环境

- 人工代理：
 - 传感器：眼睛、耳朵和其他器官。
 - 执行器：手、腿、嘴和其他身体部位。
 - 机器人代理：
 - 传感器：摄像机和红外测距仪。
 - 执行器：各种电机。
- 各地代理商！
 - 恒温器
 - 手机
 - 吸尘器
 - 机器人
 - 自动驾驶汽车
 - 苹果 Siri
 - 人类
 - ETC。


Vacuum cleaner

- Percepts: location and contents, e.g., [A, Dirty]
- Actions: Left, Right, Suck, NoOp
- **Agent function:** mapping from percepts to actions.

A



B



Percept	Action
[A, clean]	Right
[A, dirty]	Suck
[B, clean]	Left
[B, dirty]	Suck

- 理性代理：
 - "对于每个可能的感知序列，理性代理应该根据感知序列提供的证据以及代理所拥有的任何内置知识，选择一个预期能够最大化其绩效指标的动作。"
 - 合理性与绩效衡量相关。
 - 合理性判断标准：
 - 定义成功标准的绩效衡量标准
 - 代理对环境的先验知识
 - 代理可以执行的可能操作
 - 代理迄今为止的感知序列
 - 当我们定义一个理性代理时，我们将这些属性归类为 **PEAS**，即任务环境的问题规范。我们要为这个任务环境设计的理性代理就是解决方案。
 - Performance 性能
 - Environment 环境
 - Actuators 执行器
 - Sensor 传感器
 -

- 对于自动驾驶汽车来说，PEAS 是什么？



- 性能：安全、舒适、时间、合法驾驶。
- 环境：道路、其他车辆、行人、路标。
- 执行器：转向器、加速器、制动器、信号器、喇叭。
- 传感器：摄像头、声纳、GPS、速度计、里程表、加速度计、发动机传感器、键盘。

•

- 吸尘器怎么样？



- 性能：清洁度、效率：清洁行驶的距离、电池寿命、安全性。
- 环境：房间、桌子、木地板、地毯、不同的障碍物。
- 执行器：轮子、不同的刷子、真空吸尘器。
- 传感器：摄像头、污垢检测传感器、悬崖传感器、碰撞传感器、红外墙传感器。

• 环境 Environment

• 分类

- 完全可观察（vs 部分可观察）：一个智能体的传感器能够在每个时间点访问环境的完整状态。
- 确定性（vs 随机性）：环境的下一个状态完全由当前状态和智能体执行的动作决定。如果环境是确定性的，除了其他智能体的动作外，那么这个环境是策略性的。
- 情景式（vs 连续式）：智能体的体验被分割为原子化的“情景”，每个情景由智能体的感知和随后执行单一动作组成，并且每个情景中的动作选择只取决于该情景本身。
- 静态（vs 动态）：当智能体在思考时，环境保持不变。如果环境本身不随时间变化，但智能体的表现分数会变化，则称其为半动态。
- 离散（vs 连续）：环境中的感知和动作数量有限且明确。例如，跳棋是离散环境的例子，而自动驾驶汽车则在连续环境中演变。
- 单智能体（vs 多智能体）：智能体在环境中独立运行。
- 已知（vs 未知）：智能体的设计者可能了解或不了解环境的构成。如果环境是未知的，智能体需要弄清楚其工作原理才能做出决定。

•

Environment types

Environment	Observable	Agents	Deterministic	Static	Discrete
8-puzzle	Fully	Single	Deterministic	Static	Discrete
Chess	Fully	Multi	Deterministic	(Semi)Static	Discrete
Poker	Partially	Multi	Stochastic	Static	Discrete
Backgammon	Fully	Multi	Stochastic	Static	Discrete
Car	Partially	Multi	Stochastic	Dynamic	Continuous
Cleaner	partially	Single	Stochastic	Dynamic	Continuous