


Lecture 13 -- Decision trees & Naive Bayes

• Decision trees 决策树

- 决策树是从根节点向下生长的。其思想是将样本沿树向下传递，利用信息熵的概念。
- 构建决策树的一般步骤：
 - 从包含所有样本的根节点开始。
 - 贪心地选择下一个最优特征以构建分支。分裂准则是节点纯度 node purity。
 - 叶节点将被赋予多数类（多数类标签）。
- 在决策树分类器中：不需要 $x_i \in \mathbb{R}^d$ ，因此无需将类别特征转换为数值特征。
- 划分准则 (ID3) :
 - 核心选择是决定下一个用于划分的属性。
 - 我们需要一些度量节点中样本同质性 homogeneity 或杂质 impurity 的准则：
 - (a) 量化每个节点中各类的混合情况。
 - (b) 若各类样本数相等则达到最大值。
 - (c) 若节点纯净则达到最小值。
 - 一个常用且完备的度量来自信息论：（ $p_{\oplus}$ 为正例的比例， $p_{\ominus}$ 为负例的比例。）

$$Entropy(S) = -p_{\oplus} \log_2 p_{\oplus} - p_{\ominus} \log_2 p_{\ominus}$$




In general, for c classes:

$$Entropy(S) = \sum_{i=1}^c -p_i \log_2 p_i$$

- 现在每个节点都有一个熵，用以度量该节点内的同质性。
- 我们使用信息增益 Information gain 来衡量按某属性划分后熵的期望减少量：

$$Gain(S, A) = Entropy(S) - \sum_{v \in \text{Value}(A)} \frac{|S_v|}{|S|} Entropy(S_v)$$



Feature	Information Gain
Highest Degree	0.149
Work Experience	0.189
Favorite Language	0.258
Needs Work Visa	0.000

- 在从根节点开始的第一次划分中，我们选择信息增益最大的属性。
- 然后，在每个子节点（若节点不纯）重复相同过程。


剪枝策略 pruning strategies:

- 为了获得合适的树大小并避免过拟合：
 - 提前停止生长树，在其完全拟合训练样本之前停止（但很难确定何时停止）。
 - 先生长出一棵复杂的树，然后再对其进行剪枝（发现的最佳策略）。使用验证集来评估后剪枝的效果：如果去掉某子树后新树的表现不比原树差，则移除该子树。

CART:

- 采用相同的贪心自顶向下算法。
- 使用二叉划分而非多路划分。
- 使用 Gini 指数而不是信息熵：

$$Gini = 1 - p_{\oplus}^2 - p_{\ominus}^2$$



实际注意事项:

- 在训练前考虑进行降维，以保留最具区分性的特征。
- 使用集成方法，例如随机森林（Random Forest），通常具有很好的性能。
- 在训练前对数据集进行平衡，以防树偏向占主导地位类别。
 - 欠采样 under-sampling：减少多数类样本。
 - 过采样 over-sampling：为少数类生成合成数据（例如 SMOTE）。

- 优点：
 - 直观、易解释。
 - 可转换为规则。
 - 非常适合处理类别型数据。
 - 构建简单。
 - 无需对数据进行缩放。
- 缺点：
 - 不稳定（样本的微小变化可能导致生成不同的树）。
 - 单变量（每次只按一个属性划分，不进行特征组合）。
 - 某个节点的选择依赖于之前的选择。
 - 需要对数据进行平衡处理。

• Naive Bayes 朴素贝叶斯

- $p(A|B)$ 表示“在已知 B 已发生的条件下，A 发生的概率”。

$$p(A|B) = \frac{p(A \wedge B)}{p(B)}$$

$$p(A \wedge B) = p(A|B) * p(B)$$

- 贝叶斯定理

Writing $p(A \wedge B)$ in two different ways:

$$p(A \wedge B) = p(B|A) * p(A)$$

$$p(A \wedge B) = p(A|B) * p(B)$$

$$p(A|B) = \frac{p(B|A) * p(A)}{p(B)}$$

- $p(A|B)$ 称为后验 posterior（在给定 B 的条件下 A 的后验分布）。
- $p(A)$ 称为先验 prior
- $p(B)$ 称为证据 evidence
- $p(B|A)$ 称为似然 likelihood
-

	A	not A	Sum
B	P(A and B)	P(not A and B)	P(B)
Not B	P(A and not B)	P(not A and not B)	P(not B)
	P(A)	P(not A)	1

- This table divides the sample space into 4 mutually exclusive events.
- The probability in the margins are called marginals and are calculated by summing across the rows and the columns.

Another form:

$$p(A|B) = \frac{p(B|A) * p(A)}{p(B|A) * p(A) + p(B|\neg A) * p(\neg A)}$$

• 判别式算法 Discriminative algorithms:

- 想法：对 $p(y|x)$ 建模，即在给定 x 的条件下 y 的条件分布。
- 在判别式算法中：寻找一个决策边界，将正例与负例分开。
- 对新样本进行预测时，检查其落在决策边界的哪一侧。
- 直接对 $p(y|x)$ 进行建模。

• 生成式算法 Generative Algorithms:

- 思路：为正例构建一个样本分布模型（正例长什么样）。
- 为负例构建一个不同的模型（负例长什么样）。
- 要对新样本进行预测，将其分别与各模型匹配，查看哪个匹配得最好。
- 建模 $p(x|y)$ 和 $p(y)$ 。
- 使用贝叶斯定理得到

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)}$$

- 为了做出预测：

$$\operatorname{argmax}_y p(y|x) = \operatorname{argmax}_y \frac{p(x|y)p(y)}{p(x)}$$

$$\operatorname{argmax}_y p(y|x) \approx \operatorname{argmax}_y p(x|y)p(y)$$

• 设定 (Setting) :

- 训练数据 (x_i, y_i) , x_i 是特征向量, y_i 是离散标签。
- 有 d 个特征, n 个样本。
 - 示例：考虑文档分类，每个样本是一篇文档，每个特征表示某个特定词在文档中是否出现。
- 我们有一个训练集。新样本的特征值为 $x_{new} = (a_1, a_2, \dots, a_d)$ 我们想预测新样本的标签 y_{new}
- 使用贝叶斯定理

$$y_{new} = \operatorname{argmax}_{y \in \mathbb{Y}} p(y|a_1, a_2, \dots, a_d)$$

Use Bayes rule to obtain:

$$y_{new} = \operatorname{argmax}_{y \in \mathbb{Y}} \frac{p(a_1, a_2, \dots, a_d|y) * p(y)}{p(a_1, a_2, \dots, a_d)}$$

$$y_{new} = \operatorname{argmax}_{y \in \mathbb{Y}} p(a_1, a_2, \dots, a_d|y) * p(y)$$

- 我们能否从训练数据估计这两项？

- $p(y)$ 较容易估计：统计每个标签 y 在训练集中出现的频率。
- $p(a_1, a_2, \dots, a_d|y)$ 很难估计，除非我们有非常非常大的样本量。（需要多次看到每一种可能的特征组合才能得到可靠估计。）

- 朴素贝叶斯分类器：

- 概率模型。适用于自然语言文本等应用领域。在某些情况下，该方法的性能可以与决策树和神经网络相当。
- 作出一个简化假设：在已知类别标签的条件下，各特征值相互条件独立。
- 在给定样本的类别 y 的情况下，观察到特征联立 $a_1, a_2, \dots, a_d$ 的概率等于各单独特征概率的乘积：

$$p(a_1, a_2, \dots, a_d|y) = \prod_j p(a_j|y)$$

- 朴素贝叶斯分类器：

$$y_{new} = \operatorname{argmax}_{y \in \mathbb{Y}} p(y) \prod_j p(a_j|y)$$

- 我们可以从训练数据估计这两项。

- 算法：

- 学习（基于数据集中频率计数）：
 - 估计所有 $p(y)$ ，对每个标签 $y \in \mathbb{Y}$ 。
 - 估计所有 $p(a_j|y)$ ，对每个 $y \in \mathbb{Y}$ 和每个特征 a_j 。

- 分类：对新样本使用：

$$y_{new} = \operatorname{argmax}_{y \in \mathbb{Y}} p(y) \prod_j p(a_j|y)$$

- 注意：这里没有显式的模型或超平面，只是在训练样本中统计各种数据组合出现的频率。

-

Example

$$y_{new} = \operatorname{argmax}_{y \in \{yes, no\}} p(y) * p(Masters|y) * p(UX \text{ Design}|y) * p(Java|y) * p(TRUE|y)$$

$$p(yes) = 8/14 = 0.572$$

$$p(no) = 6/14 = 0.428$$

Conditional probabilities:

$$p(masters|yes) = 4/8 \quad p(masters|no) = 1/6$$

$$p(UX \text{ Design}|yes) = 2/8 \quad p(UX \text{ Design}|no) = 2/6$$

$$p(Java|yes) = 6/8 \quad p(Java|no) = 1/6$$

$$p(TRUE|yes) = 4/8 \quad p(TRUE|no) = 3/6$$

$$p(yes) * p(Masters|yes) * p(UX \text{ Design}|yes) * p(Java|yes) * p(TRUE|yes) = 0.026$$

$$p(no) * p(Masters|no) * p(UX \text{ Design}|no) * p(Java|no) * p(TRUE|no) = 0.002$$

$$y_{new} = yes$$

36

- 估计概率 (m-估计)

- m-估计公式:

$$p(a_j|y) = \frac{n_c + m * p}{n_y + m}$$

- n_y : 类别为 y 的样本总数。
 - n_c : 类别为 y 且第 j 个特征取值为 a_j 的样本总数。
 - m: 称为等效样本数。
 - p: 先验概率 (对该特征取值的先验估计)。
 - 直观: 通过加入 m 个虚拟样本 (按先验 p 分配各取值) 来扩充样本量, 从而平滑估计。
 - 如果先验未知, 可假设均匀先验: 若该特征有 k 个可能取值, 则设 $p = 1/k$ 。