

Lecture 14 -- Ensemble & Clustering

- ensemble

- 多数投票 (Majority Voting)
 - 随机选择的超平面期望错误率为 0.5。
 - 许多随机超平面通过多数投票结合起来仍然是随机的。
 - 假设我们有 m 个分类器，它们的表现略好于随机，即错误率 $= 0.5 - \epsilon$ 。
 - 组合：基于多数投票做出决策？
 - 如果我们把这些略好于随机的 m 个分类器结合起来，会发生什么？多数投票会是一个好选择吗？
 - 孔多塞陪审团定理 (Condorcet's Jury Theorem)
 - 假设：
 - 每个个体以概率 p 做出正确选择。
 - 投票是相互独立的。
 - 若 $p > 0.5$ ，增加更多投票者会提高多数决策正确的概率。
 - 若 $p < 0.5$ ，增加更多投票者会使情况变糟。
- 集成方法 (Ensemble Methods)
 - 集成方法通过多数投票将许多个体分类器的预测结合起来。
 - 这些个体分类器称为弱学习器 (weak learners)，要求其表现略好于随机。
 - 问题：如何用相同的训练数据产生相对独立的弱学习器？
 - 策略：使用某种策略以获得相对独立的弱学习器。
 - 不同的方法包括：
 - 提升 (Boosting)
 - 常用算法：AdaBoost。
 - 弱学习器可以是决策树、感知器、决策桩等。
 - 思路：在带权重的训练样本上训练弱学习器。
 - 所有弱学习器 G_m ($m \in \{1, \dots, M\}$) 的预测通过加权多数投票结合在一起。
 - α_m 表示每个弱学习器 G_m 的贡献权重。
 - α_m 由提升算法计算，用以在序列中赋予分类器不同的加权重要性。
 - 序列中表现更好的分类器的决策应被赋予比表现较差的分类器更高的权重。
 - 形式上可表示为：

$$G(x) = \text{sign}\left[\sum_{m=1}^M \alpha_m G_m(x)\right]$$

- 训练样本上的错误率定义为：

$$err := \frac{\sum_{i=1}^n 1\{y_i \neq G(x_i)\}}{n}$$

- 每个弱学习器的（带权）错误率定义为：


$$err_m := \frac{\sum_{i=1}^n w_i 1\{y_i \neq G_m(x_i)\}}{\sum_{i=1}^n w_i}$$

- 直觉 (Intuition) :

- 对难分、容易出错的样本给予较大的权重。
- 对简单、容易分类的样本给予较小的权重。

- 对于每个弱学习器 m ，关联一个错误率 err_m

- 用该错误率计算该弱学习器的权重：



$$\alpha_m = \frac{1}{2} \log\left(\frac{1-err_m}{err_m}\right)$$

- 图中曲线展示了 α_m 随 err_m 变化的关系：

- 当 err_m 小于 0.5 时 α_m 为正且随 err_m 减小而增大；
- 当 err_m 趋近 0.5 时 α_m 趋近 0；
- 当 $err_m > 0.5$ 时 α_m 为负。

AdaBoost（自适应提升）

- 插曲：决策桩（Decision Stumps）

- 这是一个非常弱的分类器示例。
- 一个简单的二叉叶节点决策树用于二分类，形式为：

$$f(\mathbf{x}) = s(x_k > c)$$

Where $c \in \mathbb{R}$, $k \in \{1, \dots, d\}$, $s \in \{-1, 1\}$.

- 决策桩通常通过暴力搜索训练：将某一特征的实数值从训练集中最小到最大离散化，枚举所有可能的分类器，选择训练误差最小的那个。

- 示例：数据集有 10 个特征，训练样本 2000 个，测试样本 10000 个。

- 装袋 (Bagging)

- 装袋 (Bagging) 与自助法 (Bootstrapping)

- 自助法 (Bootstrap) 是一种重采样技术，即从经验分布中采样。
 - 目的是提高估计量的质量。
 - 装袋 (Bagging) 和提升 (Boosting) 都基于自助法。
 - 两者都使用重采样来生成用于分类的弱学习器。
 - 策略：通过重采样随机扰动数据。
 - 在重采样得到的训练集上训练弱学习器。
 - 自助聚合 (Bootstrap aggregation) 即为装袋 (Bagging)。

- 训练 (Training)

- 对 $b = 1, \dots, B$:
 - 从训练数据中抽取一个大小为 L 的自助样本 B_b (bootstrap sample)。
 - 在 B_b 上训练一个分类器 f_b 。


- 分类 (Classification)

- 通过 B 个分类器的多数投票进行分类：

$$f_{avg} := \frac{1}{B} \sum_{b=1}^B f_b(x)$$

-

Bagging works well for trees:



- 随机森林 (Random Forests)

- 随机森林：对树的装袋方法做改进，以减少树之间的相关性 (correlation)。
 - 树的训练通常在所有维度上优化每次分裂 (即考虑所有特征来选分裂)。
 - 但在随机森林中，每次分裂时从维度集中随机选择一个不同的子集来考虑。被选择的维度数量记为 m 。
 - 在该子集内选择最优的分裂。
 - 该子集是从所有维度 $\{1, \dots, d\}$ 中随机选择的。
 - 推荐的 m 值为 $m = \sqrt{d}$ 或更小。

• clustering

• 相似性的概念：

- 相似性度量的选择对聚类非常重要。
- 相似性与距离成反比（相似性越大，距离越小）。
- 不同的距离度量方法：

- 欧氏距离 Euclidean distance：

$$d(\mathbf{x}, \tilde{\mathbf{x}}) = \|\mathbf{x} - \tilde{\mathbf{x}}\|_2$$

- 曼哈顿距离 Manhattan distance：

$$d(\mathbf{x}, \tilde{\mathbf{x}}) = \sum_{i=1}^d |\mathbf{x}_i - \tilde{\mathbf{x}}_i|$$

- 核化距离 Kernelized distance：（在特征映射空间中计算的距离）

$$d(\mathbf{x}, \tilde{\mathbf{x}}) = \|\phi(\mathbf{x}) - \phi(\tilde{\mathbf{x}})\|$$

• 聚类：K-Means 算法

• 算法步骤：

- 随机初始化 $\mu_1, \dots, \mu_k$ （k 个簇的质心）。
- 重复：
 - 将每个点 x_i 分配给与其最近的簇中心 μ_j 。
 - 计算每个簇的新均值：


$$\mu_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i$$

- 直到收敛为止。【收敛的定义：簇分配不再变化，或达到预设的最大迭代次数。】
- 目标：将每个样本 $(x_1, \dots, x_n)$ 分配到 k 个簇 $\{C_1, \dots, C_k\}$ 之一。
- μ_j 是第 j 个簇中所有样本的均值。
- 最小化目标函数：

$$J = \sum_{j=1}^k \sum_{x_i \in C_j} \|x_i - \mu_j\|^2$$

- 精确地优化 K-means 的目标是 NP-hard 问题。K-means 算法是一个启发式方法，会收敛到某个局部最优解。
- 优点：实现简单
- 但存在的问题：
 - 需要事先知道 K（簇数）

- 受维度灾难影响
- 缺乏理论基础
- K-Means：待解决的问题
 - 如何设置 k 以便对数据进行最优聚类？（肘点法）
 - 一种选择 K 的方法是尝试不同的 K 值，绘制 K-means 目标函数随 K 的变化曲线，然后在图中寻找“肘点”（elbow point）。
 - 对下图而言， $K = 2$ 是肘点。



- 如何设置 k ：G-means 算法
 - 将 k 初始化为一个较小的数值。
 - 用这些簇中心运行 k-means，并将得到的中心存为集合 C 。
 - 将每个点分配到其最近的簇。
 - 判断每个簇内的点是否服从高斯分布（使用 Anderson-Darling 检验）。
 - 对于每个簇：如果簇内点看起来近似正态分布，则保留该簇中心；否则，将该簇中心替换为两个簇中心（即分裂该簇）。
 - 从第 2 步重复该算法，直到不再生成新的簇中心为止。
- 如何评估你的模型？
 - 内部评估（Internal evaluation）：在同一数据上评估，期望簇内相似度高（簇内文档相似）且簇间相似度低。例：Davies-Bouldin 指数同时考虑簇内距离和簇间距离。该指数越小，说明不同簇之间分离越明显、簇内点越紧密聚集。
 - 外部评估（External evaluation）：使用外部数据的真实标签（ground truth）。例如：互信息（mutual information）、熵（entropy）、调整兰德指数（adjusted Rand index）等。
- 如何聚类非圆形（非球状）的簇？
 - 其它方法可以处理非圆形簇：谱聚类（spectral clustering）、核化 K-means（kernelized K-means）、DBSCAN、BIRCH 等。
- 如何初始化簇中心？
 - K-means 对簇中心的初始化极为敏感。
 - 不良的初始化可能导致：
 - 收敛速度慢
 - 整体聚类效果差

- 保护性措施（初始化策略）：
 - 例如：选择第一个中心为某个样本，第二个中心选择与第一个最远的样本，第三个选择与前两个最远的样本，依此类推（类似远距初始化思想）。
 - 尝试多次不同初始化并选择最优结果（多次运行取最好）。
- 其它限制
 - 对点做“硬”分配（hard assignments）：
 - 一个点要么完全属于某个簇，要么不属于。
 - 没有“软”分配的概念（即没有给出属于各簇的概率）。例如 $K=3$ 时，某点可能有 $p_1=0.7$ 、 $p_2=0.2$ 、 $p_3=0.1$ 的属于概率。
 - 高斯混合模型（Gaussian Mixture Models）允许软分配。
 - 对离群点（outliers）敏感：
 - 对含离群点的数据，K-median 算法是更稳健的替代方法。
 - 原因：在存在离群点时，中位数比均值更具鲁棒性。